Avaliação de Filtros Espaciais e Binarização para Detecção de Derramamentos de Óleo no Oceano em Imagens SAR

Carolina Barroco[1], **Gustavo Lösch**[1], **Henrique Mayer**[1]

[1] Escola Politécnica – Pontíficia Universidade Católica do Rio Grande do Sul (PUCRS)

{carolina.barroco, g.losch, h.ramos}@edu.pucrs.br

Resumo. *O monitoramento de derramamentos de óleo em ambientes oceânicos é uma tarefa crítica para a preservação ambiental. Este trabalho propõe uma abordagem sistemática para a identificação do pipeline de processamento de imagem ideal para a segmentação de manchas de óleo, utilizando o conjunto de dados Refined Deep-SAR Oil Spill (SOS). A metodologia baseia-se na aplicação de filtros espaciais de ruído combinados com técnicas de binarização, cujos hiperparâmetros são otimizados por meio de Otimização Bayesiana através do framework Optuna. Quatro configurações de filtro foram avaliadas: mediana, gaussiano, bilateral e média. Os resultados, mensurados pela métrica Mean Squared Error (MSE), demonstraram que o Filtro Bilateral obteve o melhor desempenho empírico geral (MSE de 0.127 com limiar otimizado de 67), enquanto o Filtro de Mediana destacou-se pela maior consistência frente às variações de ruído nas imagens SAR.*

1. Introdução

O monitoramento e identificação de derramamentos de óleo em ambientes oceânicos é uma tarefa crítica para a preservação ambiental e a segurança marítima. Imagens de Radar de Abertura Sintética (SAR) têm sido amplamente utilizadas para este propósito [Murugan et al. 2026, Zhu et al. 2022, Del Frate et al. 2000] devido à sua capacidade de operar em diversas condições climáticas e períodos do dia. No entanto, o ruído intrínseco a essas imagens e a complexidade na diferenciação entre manchas de óleo e outros fenômenos oceânicos tornam a segmentação automática um desafio.

Este trabalho propõe uma abordagem sistemática para a identificação do pipeline de processamento de imagem ideal para a segmentação de manchas de óleo, utilizando o conjunto de dados Refined Deep-SAR Oil Spill (SOS) [Zhu et al. 2022]. A metodologia baseia-se na aplicação de filtros de ruído combinados com técnicas de binarização, cujos hiperparâmetros são otimizados utilizando otimização bayesiana através do framework Optuna [Akiba et al. 2019]. O objetivo principal é determinar qual combinação de pré-processamento e limiarização maximiza a precisão da segmentação em comparação com as máscaras de referência.

A contribuição deste artigo reside na avaliação empírica de técnicas clássicas de processamento digital de imagens aplicadas a um dataset SAR refinado, estabelecendo uma *baseline* e métricas de desempenho (MSE) que auxiliam na compreensão de como filtros espaciais impactam a segmentação de alvos em imagens de satélite.

O restante deste artigo está estruturado da seguinte forma: a Seção 2 apresenta os fundamentos teóricos dos filtros e técnicas utilizadas, além de descrever o conjunto de dados; a Seção 3 detalha a

implementação do processamento e a estratégia de otimização; a Seção 4 apresenta e discute os resultados obtidos; e, por fim, a Seção 5 sintetiza as conclusões e sugere trabalhos futuros. O código do projeto pode ser encontrado em um repositório público[1] no GitHub.

2. Background

2.1. Filtros

Os filtros espaciais são aplicados para atenuar o ruído e suavizar a imagem antes da binarização, facilitando a separação do objeto de interesse. Foram selecionados quatro métodos distintos de filtragem implementados utilizando o pacote OpenCV [Bradski 2000].

O Filtro de Mediana atua substituindo o valor de cada pixel pela mediana das intensidades dos pixels ao seu redor. Essa abordagem é muito eficiente para remover ruídos isolados e extremos, como o ruído "sal e pimenta", que costuma aparecer como pequenos pontos brancos ou pretos espalhados pela imagem. A principal vantagem do uso da mediana é a sua capacidade de limpar essas imperfeições sem borrar as bordas dos objetos, mantendo os contornos das manchas de óleo bem definidos para a etapa de segmentação.

O Filtro Gaussiano aplica uma suavização na imagem calculando uma média ponderada dos pixels vizinhos. Nesse método, os pixels mais próximos ao centro recebem um peso maior na conta, e essa influência diminui gradativamente para os pixels mais distantes, seguindo uma distribuição normal. O resultado é um desfoque mais natural e suave, excelente para reduzir variações contínuas de ruído por toda a imagem, embora traga como efeito colateral um leve borramento geral que pode suavizar bordas finas.

[1] github.com/HenriqueMayer/t1-introducao-a-visao-computacional

O Filtro Bilateral é uma técnica projetada para suavizar a imagem preservando ativamente os seus contornos. Para calcular o novo valor de um pixel, ele considera não apenas a proximidade espacial dos vizinhos, mas também a semelhança de intensidade entre eles. Na prática, o filtro aplica um forte borramento em áreas com cores uniformes, como o fundo do oceano, mas reduz esse efeito ao encontrar uma transição brusca de intensidade. Isso garante que a nitidez das bordas entre óleo e oceano seja mantida.

O Filtro de Média (Blur) é o método mais simples de suavização, operando através do cálculo da média aritmética de todos os *pixels* dentro de uma determinada vizinhança. O seu objetivo é homogeneizar a região, reduzindo as diferenças bruscas de intensidade entre os *pixels* próximos e diminuindo o ruído global. Contudo, por tratar todos os *pixels* da vizinhança com exatamente o mesmo peso, o filtro de média acaba borrando a imagem inteira de maneira uniforme, o que frequentemente degrada as delimitações e detalhes geométricos da imagem.

2.2. Binarização

A binarização é o processo de conversão de uma imagem em tons de cinza para uma representação binária (preto e branco). Neste projeto, a operação é definida por um limiar T. *Pixels* com intensidade superior a T são mapeados para o valor 255 (branco), enquanto os demais tornam-se 0 (preto). Adicionalmente, implementou-se a lógica de inversão, crucial para *datasets* onde o alvo (mancha de óleo) possui intensidades menores que o fundo (oceano), permitindo que o objeto de interesse seja corretamente representado como a classe positiva.

2.3. Conjunto de Dados

O conjunto de dados utilizado neste trabalho é o Deep-SAR Oil Spill (SOS)

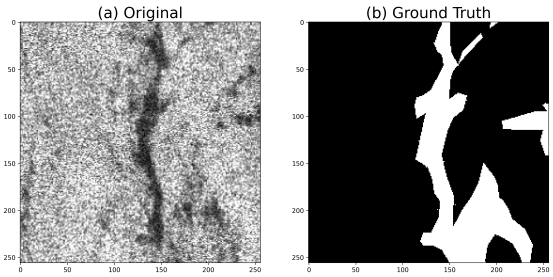

Figura 1. Exemplo de (a) imagem original e sua respectiva (b) máscara da posição da mancha de óleo no dataset DeepSAR Oil Spill (SOS).

[Zhu et al. 2022], criado para suprir a escassez de dados confiáveis e de alta qualidade para a detecção de derramamentos de óleo. As imagens do *dataset* são geradas por sensores de Radar de Abertura Sintética (SAR), uma tecnologia de sensoriamento remoto capaz de fotografar a superfície terrestre sob qualquer condição climática ou horário. Nas imagens SAR, a camada de óleo na superfície da água atenua a força das ondas, tornando o mar mais ”liso”. Isso faz com que as áreas afetadas reflitam menos o sinal do radar, aparecendo como manchas escuras que contrastam com o fundo oceânico.

O dataset foi construído a partir de 21 imagens brutas capturadas por satélites (ALOS PALSAR e Sentinel-1A) durante grandes incidentes reais no Golfo do México e no Golfo Pérsico. O grande diferencial deste conjunto é o seu processo de criação: as máscaras de segmentação originais foram refinadas e corrigidas manualmente por especialistas para eliminar ruídos e falsos positivos. É possível verificar um exemplo de imagem e a sua correspondente máscara do *dataset* na Figura 1. Para expandir o volume e a variedade do conjunto, os autores originais aplicaram técnicas de aumento de dados, como recortes, rotações e adição de ruído, garantindo que os modelos treinados com essas imagens se tornem tolerantes a diferentes perspectivas e cenários marítimos.

Em sua estrutura final, o dataset SOS disponibiliza 8.070 imagens de satélite convertidas para escala de cinza, todas com resolução padronizada de 256x256 pixels e pareadas com suas respectivas máscaras binárias de referência (ground-truth). Esses dados já se encontram divididos em uma proporção de 80% para a etapa de treinamento e 20% para a etapa de teste.

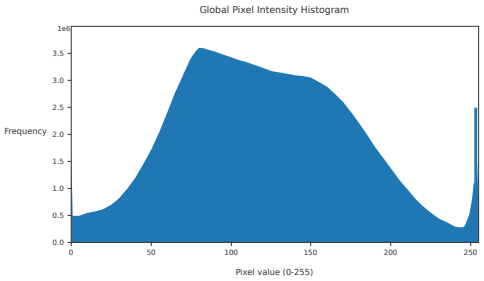

Figura 2. Histograma global de intensidade de pixel das imagens de treino.

3. Metodologia

A metodologia do trabalho é estruturada em duas frentes: a busca pelo melhor pré-processamento das imagens e a determinação do valor ótimo de T para a binarização. O fluxo do trabalho consiste no carregamento dos dados, seguido pela seleção e otimização iterativa de cada técnica de filtragem, definição do melhor limiar para cada filtro e, por fim, pela avaliação do desempenho. O pipeline desenvolvido pode ser visto na Figura 3.

3.1. Quantificação de Ruído

Ao analisar as imagens presentes nos dados, percebeu-se uma grande quantidade de ruídos do tipo “sal e pimenta” nas áreas da imagem correspondentes ao oceano. Para quantificar esse ruído, foi gerado o histograma global de intensidade de pixel das imagens de treino, conforme evidenciado

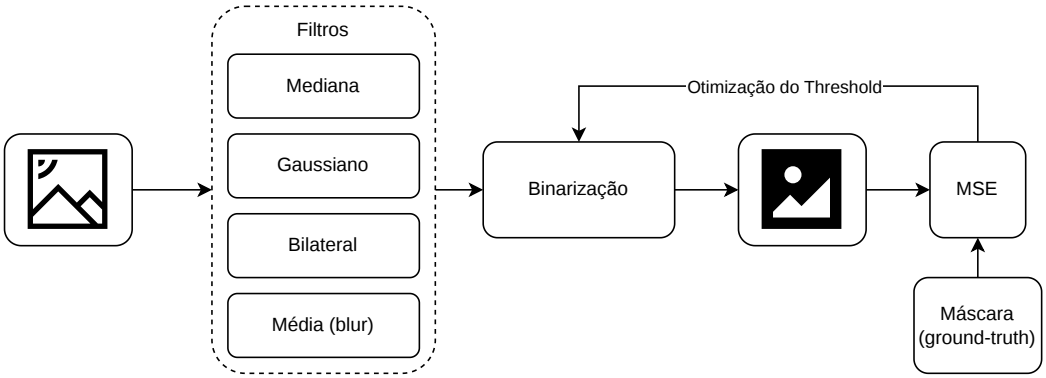

Figura 3. Pipeline de processamento proposto para segmentação de manchas de óleo em imagens SAR. A imagem de entrada é submetida a um dos quatro filtros espaciais avaliados, seguida pela binarização com limiar T otimizado via Optuna. O resultado é comparado à máscara de referência (*ground truth*) para calcular a métrica MSE, utilizada como função objetivo durante a otimização.

na Figura 2. O histograma evidencia uma distribuição ampla de intensidades, com pico em torno do valor 80, o que motivou a investigação de diferentes filtros espaciais para atenuar essas irregularidades antes da etapa de binarização. A imagem evidencia outro pico próximo ao valor 250, indicando a existência do ruido "sal e pimenta" mencionado anteriormente.

3.2. Processamento de Imagens

Após a análise de quantificação de ruído, foi realizada a aplicação de filtros para o processamento das imagens. Inicialmente, a imagem é submetida a um dos quatro tipos de filtragem espacial: (a) filtro de mediana, (b) filtro gaussiano, (c) filtro bilateral e (d) filtro média (blur). O propósito dessa etapa é atenuar os ruídos e artefatos presentes nas imagens SAR que interferem negativamente na delimitação das áreas com o derramamento de óleo. Cada filtro foi testado com diferentes valores de T e avaliados utilizando MSE, assim conseguindo quantificar qual seria o melhor filtro para a detecção de manchas de óleo. O resultado do processo de filtragem é uma imagem modificada contendo, possivelmente, menos ruído do que a imagem original, mostrado na Figura 4.

3.3. Binarização

Após a utilização dos filtros, aplica-se o processos de binarização. Esta etapa converte as representações em tons de cinza para matrizes binárias, utilizando um limiar T. A fim de encontrar estatisticamente o melhor limiar para executar a binarização, fora utilizado métodos tradicionais conhecidos na área de *machine learning* para otimizar funções. Utilizando o pacote Optuna [Akiba et al. 2019] buscamos o melhor valor para T que minimiza o MSE entre a imagem binarizada e a máscara presente no *dataset* para cada filtro empregado.

Adicionalmente o *pipeline* incorpora um parâmetro de inversão. Esta funcionalidade é necessária em cenários onde o objeto de detecção (mancha de óleo) apresenta intensidade mais escura que o plano de fundo (água), permitindo que a binarização seja invertida para assegurar que o objeto seja corretamente mapeado e comparado com a máscara.

4. Resultados

Nesta seção, são apresentados os resultados das avaliações do pipeline de processamento. A análise é dividida na exploração dos hiperparâmetros encontrados pelo algoritmo de otimização Optuna e, subsequentemente, na avaliação do desempenho de cada filtro mensurado pelo MSE.

Tabela 1. Hiperparâmetros otimizados via Optuna para cada filtro.

Filtro	Limiar (T)
Ausência (None)	56
Mediana	62
Média (Blur)	62
Bilateral	67
Gaussiano	254

Tabela 2. Desempenho dos filtros avaliado pela métrica MSE entre imagem binarizada e máscara do dataset. (média $\pm$ desvio padrão)

Filtro	MSE
Bilateral	**0.127** $\pm$ 0.122
Mediana	0.128 $\pm$ **0.116**
Média (Blur)	0.129 $\pm$ 0.117
Ausência (None)	0.173 $\pm$ 0.117
Gaussiano	0.247 $\pm$ 0.228

4.1. Otimização de Hiperparâmetros

A Tabela 1 detalha os melhores conjuntos de hiperparâmetros (limiar de binarização) encontrados pelo Optuna para cada técnica de filtragem após a varredura do espaço de busca no conjunto de treinamento.

Com exceção do filtro Gaussiano, observa-se uma forte consistência nos hiperparâmetros ideais. Os limiares de corte T concentraram-se em uma faixa estreita próxima da coloração preta (entre 56 e 67), e a condição de inversão lógica (*inverse = True*) foi selecionada por unanimidade nos modelos de melhor desempenho. Este comportamento mostra uma característica física das imagens SAR para o monitoramento de derramamentos: as manchas de óleo causam um amortecimento do sinal do radar, resultando em regiões mais escuras do que o oceano em volta. A inversão garante que essas regiões de baixa intensidade sejam corretamente convertidas para a classe positiva (branco) na máscara binária final.

4.2. Desempenho dos Filtros

É possível verificar um exemplo da aplicação dos filtros nas imagens do dataset na Figura 4, assim como um exemplo do processo de binarização com os melhores parâmetros em cada filtro na Figura 5. A análise quantitativa da Tabela 2 revela o Filtro Bilateral como a melhor técnica de filtragem de ruído, alcançando o menor índice de erro médio (MSE=0.127). Este resultado mostra que o filtro bilateral consegue mitigar o ruído nas zonas homogêneas do oceano sem degradar as fronteiras complexas das manchas de óleo, o que resulta em uma binarização altamente fiel à máscara de referência.

Os filtros de Mediana e Média (Blur) apresentaram desempenhos expressivos e estatisticamente próximos entre si, com erros médios em torno de 0.128. Destaca-se, entretanto, a consistência do Filtro de Mediana, que registrou o menor desvio padrão de todo o experimento (0.116). Isso indica que, embora o filtro bilateral seja pontualmente mais preciso, o filtro de mediana é o método mais consistente, mantendo uma taxa de acerto estável perante as variações de iluminação e ruídos presentes nas mais de 8.000 imagens do *dataset* SOS.

A aplicação adequada de processamento de sinais provou-se fundamental, visto que a Ausência de Filtro (None) resultou em um erro base significativamente superior (MSE=0.173). O ruído não tratado na imagem original gera falsos positivos (anomalias espalhadas pelo oceano) durante a limiarização, comprometendo a identificação do alvo principal.

Por fim, o Filtro Gaussiano de-

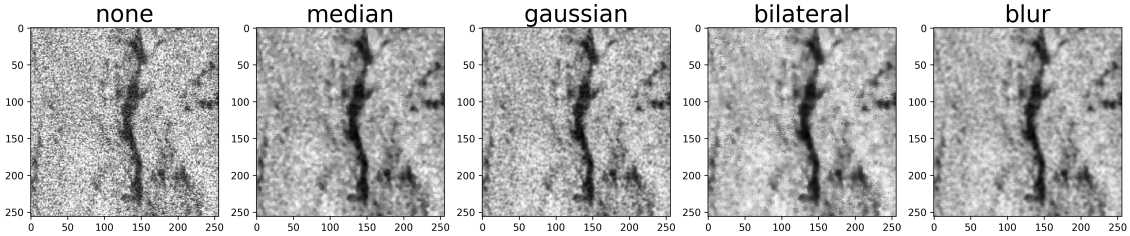

Figura 4. Aplicação de diferentes filtros em comparação com a imagem original (none).

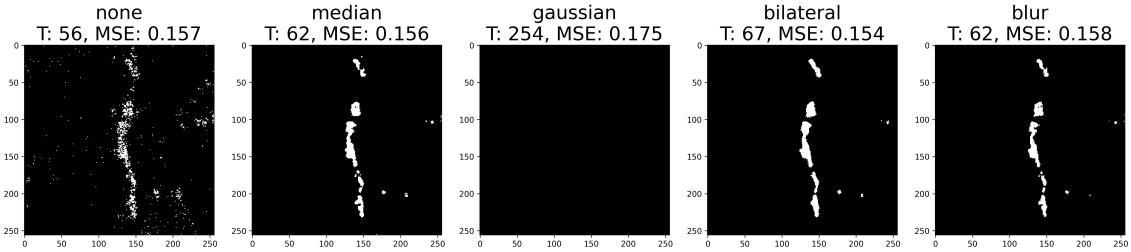

Figura 5. Exemplo de binarização de imagens utilizando diferentes filtros com o melhor valor T encontrado.

monstrou uma falha de adequação severa para esta tarefa específica, apresentando o pior desempenho global (MSE=0.247) e a maior variância (0.228). A análise retrospectiva dos hiperparâmetros deste filtro (Tabela 1) ilustra um colapso do processo de otimização: o espalhamento do núcleo gaussiano borrou excessivamente as fronteiras das manchas de óleo a ponto de fundi-las ao oceano. Diante dessa perda de informação, a otimização de hiperparâmetros adotou um limiar máximo (T=254), convertendo praticamente toda a imagem para a coloração preta na tentativa de minimizar as penalidades matemáticas, falhando assim no objetivo primário de segmentação.

5. Conclusão

Este trabalho abordou o problema da segmentação automática de manchas de óleo em imagens de satélite SAR, uma tarefa de relevância ambiental direta cujo principal desafio reside na presença de ruído intrínseco ao processo de aquisição e na dificuldade de distinguir alvos de interesse de outros fenômenos oceânicos de aparência semelhante.

Para enfrentar esse desafio, foi proposta e avaliada uma metodologia sistemática baseada em técnicas clássicas de processamento digital de imagens. O pipeline desenvolvido combina uma etapa de filtragem espacial para atenuação de ruído com uma etapa de binarização por limiar, cujos hiperparâmetros foram determinados de forma automática por meio de Otimização Bayesiana via framework Optuna, minimizando o MSE em relação às máscaras de referência do dataset SOS.

Os experimentos conduzidos sobre as 8.070 imagens do conjunto de dados demonstraram que a escolha do filtro de pré-processamento exerce impacto direto e significativo na qualidade da segmentação. O Filtro Bilateral, com limiar otimizado $T = 67$, obteve o melhor desempenho geral (MSE= 0.127), ao passo que o Filtro de Mediana destacou-se pela maior consistência entre as imagens, registrando o menor desvio padrão do experimento. O Filtro Gaussiano, por sua vez, revelou-se

inadequado para a tarefa, com o processo de otimização colapsando para um limiar que inviabilizou a segmentação.

Como trabalhos futuros, sugere-se a investigação de operações de pós-processamento para refinamento das máscaras geradas, a avaliação de métricas complementares como o Coeficiente de Dice e o IoU (*Intersection over Union*), e a comparação da abordagem clássica aqui estabelecida como *baseline* com métodos de aprendizado de máquina, como redes neurais, para verificar o ganho obtido com técnicas de maior complexidade computacional.

Referências

Akiba, T., Sano, S., Yanase, T., Ohta, T., and Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*.

Bradski, G. (2000). The OpenCV Library. *Dr. Dobb's Journal of Software Tools*.

Del Frate, F., Petrocchi, A., Lichtenegger, J., and Calabresi, G. (2000). Neural networks for oil spill detection using ers-sar data. *IEEE Transactions on Geoscience and Remote Sensing*, 38(5):2282–2287.

Murugan, J. S., Ramkumar, K., Kshirsagar, P. R., and Tak, T. K. (2026). Satellite-based oil spill detection using an explainable ViR-SC hybrid deep learning ensemble for improved accuracy and transparency. *Scientific Reports*, 16(1):6637.

Zhu, Q., Zhang, Y., Li, Z., Yan, X., Guan, Q., Zhong, Y., Zhang, L., and Li, D. (2022). Oil spill contextual and boundary-supervised detection network based on marine sar images. *IEEE Transactions on Geoscience and Remote Sensing*, 60:1–10.